数据治理与NLP实践沟通交流会-12.26

◆ **会议纪要：**

！技术中心提示：第二和第三章节由人工智能技术生成，不完全代表部门观点

一、会议信息

> 1.1 **会议时间**：2025 年 12 月 26日 8:30-10:00
> 1.2 **会议地点**：设计研究院会议室
> 1.3 **参会人员：夏斐、刘念、徐正玲、夏国玺、杨悦**
> 1.4 **会议主题：数据治理与NLP实践沟通交流会**

二、章节纪要

1. 数据治理体系与文件夹架构梳理
   会议开始部分强调了徐正玲需要理解整个数据治理体系及其相关架构，特别是两个关键文件夹的内容整理。要求将所有与数据相关的资料归集其中，并理解其组织管理逻辑，为后续工作打下基础。
2. 人工智能背景下数据功能的划分
   讨论在人工智能发展背景下，数据所承担的三种主要功能：文本、图像和算法处理。明确技术中心内深度学习（图像）、NLP（自然语言处理）和强化学习（求最优解）三者之间的区别，帮助团队成员建立清晰的技术方向认知。
3. 高质量数据集资源指引与规范查阅
   指导团队成员查看国内外主流数据集平台（如Hugging Face、谷歌、百度、阿里），重点推荐中文优先的高质量资源。强调必须首先查阅国家发布的《高质量数据集建设指引》和《人工智能高数据建设指南》等官方规范，确保方向正确。
4. 利用AI工具辅助数据治理流程
   提出未来工作中应充分利用AI工具辅助每一步操作，例如通过Cursor或Notebook工具执行任务，并建议将具体问题输入AI以获取指南中的解决方案，提升效率并保证方法合规。
5. 材料代码识别项目的数据集构建
   确定杨悦当前核心任务是围绕材料代码构建文字类NLP数据集，明确该数据集将以文本为主，参考NLP方向进行处理。强调需从原始描述出发，建立标准化的数据输入流程。
6. NLP分词与标注技术原理讲解
   详细讲解NLP处理中的关键技术环节：分词与BIO标注。介绍jieba分词模型的应用及局限性，指出需训练更精准的领域专用模型。同时说明BIO标签在实体识别中的作用，并强调目前缺乏带标签训练数据的问题。
7. 模型训练全流程与反馈机制建立
   阐述完整的模型训练路径：数据收集→分类打标→模型训练→反馈库建立→优化评测。鼓励团队走完一遍完整流程以掌握核心技术，后续再根据实际需求探索改进方案。
8. 电力电缆名称识别任务分解
   明确当前首要目标是让模型准确识别“电力电缆”为一个完整名称而非拆分为独立字词。区分两步走战略：第一步识别名称，第二步映射编码。强调理解底层原理对后续调优的重要性。
9. 基于大模型的微调与技术创新思路
   提倡不仅要使用AI完成预测任务，更要深入理解并修改模型内部结构（如反馈层、连接层）来实现性能突破。举例说明通过结构调整可大幅提升评分，从而产出高水平论文。

10. 数据来源验证与平台协作推进
    指出吴有鹏提供的分类数据存在问题，要求回归原始设计文档提取真实描述。强调需与张晓等人协作，确认数据源头准确性，并推动搭建统一的数据标注与共享平台。
11. 系统化学习与知识整合建议
    建议杨悦结合大学所学课程内容，在实践中不断回顾和串联已有知识。通过小场景切入（如多维表处理），交替进行体系研究与具体任务，形成螺旋上升的学习模式。
12. 数据规模展望与团队协作文化倡导
    指出当前处理的数据量仅占总量极小比例，未来数据维度将极大扩展。倡导自主学习、主动沟通的团队氛围，鼓励成员在不懂中探索成长，共同面对挑战。
13. 阀门分类准备与数据重心转移
    提出下一步考虑启动阀门分类准备工作，但明确此任务不宜由杨悦主导。重申今年整体工作重心将全面转向数据体系建设，要求徐正玲和伍冰艳牵头建立管道理论重量库，推动数据资产积累。

三、 总结性引入

以下是对会议内容的要点提炼，涵盖人员职责、数据治理、技术问题及人员安排等多个方面。

南京南化建设有限公司 夏斐 | 5299

数据治理与NLP文本构建

本次分享：基于NLP的材料代码文本标注与数据集构建方法论

核心技术流程

技术方向界定 AI选型

明确三大AI方向：深度学习用于图像，强化学习用于优化，NLP专注文本，本项目聚焦NLP领域

规范研读 政策依据

系统学习《高质量数据集建设指引》《人工智能高数据建设指南》，确保符合2025年最新国家标准

BIO标注流程 结构化处理

采用结巴分词 + BIO标签体系，构建从原始材料描述到六类标准化代码的映射训练集

协同平台建设 协作机制

借鉴"穿云"模式搭建在线标注平台，支持多人协同完成大规模BIO标签标注与反馈闭环

关键实施要素

理论基础 知识重构

- 重温大学数据结构与算法课程
- 关联当前任务理解分词、序列标注原理
- 避免依赖黑箱大模型，掌握底层机制
- 通过实战重建NLP认知体系

从工具使用者转向技术理解者

数据规模 潜力巨大

- 当前仅17,000+条材料代码
- 每条可衍生多维数据库记录
- 支持电力电缆、阀门等扩展场景
- 数据资产价值远超当前体量

小数据起点，大体系蓝图

基础设施 年度重点

- 杨越牵头建设管道重量库
- 整合Hugging Face、阿里云等平台资源
- 建立中英文数据源对照机制
- 为模型训练提供结构化支撑

数据基建先行，模型才有根基

组织协作机制

核心团队分工 责任到人

- 徐江林：主导数据治理体系架构设计
- 杨越：牵头管道重量库与标注平台建设
- 夏国新：负责模型训练与评估迭代
- 张晓、吴友鹏：提供平台资源与电器数据支持

跨团队协同是项目成败关键

学习策略 以学促干

- 优先学习头部平台NLP实战课程
- 从多维表处理等小场景切入
- 边标注边理解模型结构
- 鼓励修改网络层（如添加反馈）

不依赖大模型输出，要掌握构建逻辑

技术路径与展望

模型选型 轻量微调

- 优先尝试Transformer、FNN等轻量结构
- 在千万级0.6B模型基础上微调
- 避免直接调用GPT等黑箱模型
- 追求可解释性与可优化性

模型是工具，原理是根基

阶段目标 分步推进

- 第一阶段：完成材料代码BIO标注集
- 第二阶段：验证电力电缆识别效果
- 第三阶段：扩展至阀门等品类
- 第四阶段：形成可复用数据治理范式

从单点突破到体系构建

长期愿景 智能基建

- 构建企业级材料语义理解中枢
- 实现文本→代码的自动化映射
- 沉淀标准数据集与标注规范
- 支撑AI驱动的工程材料管理

让数据说话，让AI赋能工程

以NLP为引擎，以数据治理为骨架，构建可扩展、可复用的工业文本智能处理体系，推动从经验驱动向数据驱动转型。

由AI听记生成

会议围绕数据治理体系与人工智能背景下的数据集构建展开，重点讲解了技术中心内强化学习、深度学习与NLP三大方向的区别，明确当前工作应聚焦于NLP领域的文本数据处理。要求团队以材料代码识别为切入点，系统梳理国家发布的高质量数据集建设指引等规范性文件，并利用AI工具辅助理解与实践。核心任务是构建用于训练的BIO标签数据集，通过分词与标注流程实现对材料描述的结构化处理，进而训练模型完成从原始文本到标准化代码的映射。强调需掌握技术原理而非仅依赖大模型直接输出，鼓励结合课程资

源深入学习NLP基础方法，并建议建立共享平台支持标注协作。后续将逐步推进电力电缆等具体类别的识别任务，同时启动管道重量库等数据基础设施建设。

技术架构与方向界定

- 三大AI技术方向区分
  - 深度学习主要处理图像数据
  - NLP（自然语言处理）专注于文字信息处理
  - 强化学习侧重于算法优化与最优解求解
- 数据治理组织管理
  - 徐正玲负责梳理数据治理体系的整体架构
  - 明确两个核心文件夹的内容归属与管理职责

数据集建设与规范学习

- 权威指南研读
  - 重点学习《高质量数据集建设指引》和《人工智能高数据建设指南》
  - 这些为2025年新发布，代表最新政策导向与技术标准
- 主流数据平台使用
  - 推荐优先使用Hugging Face平台的数据集资源
  - 参考Google、百度、阿里等平台，注意中英文数据源差异
  - 平台提供丰富NLP相关数据集，可用于搜索与下载

NLP任务实施路径

- 明确项目目标
  - 当前任务聚焦于“材料代码”相关的文本数据识别
  - 输出结果需转化为六个标准化标签
- 核心技术流程
  - 第一步：进行中文分词处理，使用如结巴分词等预训练模型
  - 第二步：对分词结果打BIO标签，构建有监督训练数据集
  - 第三步：模型训练与预测，评估准确率并迭代优化
  - 第四步：建立反馈机制，形成闭环优化体系
- 模型选择与改进
  - 可尝试Transformer、FNN等多种模型结构
  - 鼓励在现有大模型基础上进行微调（如千万级0.6B模型）
  - 强调理解底层原理，具备修改网络结构（如添加反馈层）的能力以提升性能

平台与协作机制建设

- 标注平台规划
  - 借鉴张笑团队“氚云”任务模式，搭建在线标注系统
  - 支持多人协同完成大规模BIO标签标注工作
- 跨团队协作
  - 杨悦与夏国玺配合推进数据集构建与模型训练
  - 与张笑沟通整合现有平台资源或自建新系统
  - 吴有鹏提供电器类数据支持，但需验证其分类准确性

学习与执行策略

- 理论与实践结合
  - 先学习头部教育平台NLP实战课程，掌握分词与标注原理
  - 实践从小场景切入（如多维表处理），逐步扩展至完整体系
- 知识体系重构
  - 回顾大学所学课程内容，将其与当前任务关联起来
  - 在实践中重新理解数据结构、算法等基础知识的应用价值

数据基础建设拓展

- 数据规模认知
  - 当前已有的17000多条材料代码仅为总量极小部分
  - 每条数据可衍生出多个维度的数据库记录，潜力巨大
- 新增任务方向
  - 在管道类材料之后，将推进电力电缆类别的识别工作
  - 阀门分类任务可交由其他人员先行准备，确保整体进度
- 基础设施启动
  - 徐正玲牵头建立管道重量库，作为年度数据工作的重点之一
  - 所有工作重心向数据治理与体系建设转移、

待办

- 徐正玲梳理数据治理体系与架构相关的两个文件夹内容
- 杨悦查看hugging face、谷歌、百度和阿里数据集，重点研究hugging face平台
- 徐正玲阅读高质量数据集建设指引和人工智能高数据建设指南等国家规范文件
- 徐正玲整理国家发布的数据集相关指南和规范，并归集到智库中进行系统梳理

- 杨悦基于材料代码构建文字型数据集，参考NLP方向开展工作
- 夏国玺按照NLP原理课程内容完成学习，重点理解模型训练与微调机制
- 杨悦补充建立BIO标签数据集，为后续模型训练提供基础
- 夏国玺及杨悦研究更优的分词模型替代Jieba，并评估现有表格形式是否合适
- 夏国玺搭建或优化一个在线标注平台，支持团队协作完成BIO标签标注任务
- 徐正玲查阅知识库中的数据程度相关文档及2018版模型相关资料
- 徐正玲牵头建立管道重量库，作为今年数据工作的重点任务之一

南京南化建设有限公司 夏斐 | 5299