材料代码系统人工智能相关交流会

◆ **会议纪要：**

！技术中心提示：第二和第三章节由人工智能技术生成，不完全代表部门观点

一、会议信息

> 1.1 **会议时间：**2026 年 2 月 5 日 18:30-19:30
> 1.2 **会议地点：**设计研究院会议室
> 1.3 **参会人员：夏斐、刘念、徐正玲、汤冉、张笑、夏国玺、成哲辉**
> 1.4 **会议主题：材料代码系统人工智能相关交流会**

二、章节纪要

南京南化建设有限公司 夏斐 | 5299

会议围绕材料代码生成逻辑与技术实现路径展开，重点讨论了当前基于规则与模型结合的方法在提取材料参数时面临的挑战。团队已尝试通过NER模型与大模型提示词工程进行六类关键参数的提取，并利用映射表与向量匹配进行标签标准化，但存在处理速度慢、泛化能力弱、相似样本误判等问题。同时，团队提出未来在图神经网络、矢量图纸识别、SLAM三维建模等方向的技术探索需求，并探讨了以长期顾问形式推进合作的可行性。

材料代码生成机制

- **参数提取逻辑**

- 材料描述中提取六类关键参数：名称、公称直径、壁厚、压力等级、材质、标准号。
- 各参数按固定缩写规则编码，如法兰为F，DN300对应300，SCH80缩写为S80，CL600转为C600，A105保持不变，ASME B16.5简写为AB165。
- 不论原始描述顺序如何变化，相同材料最终生成统一代码，例如F300S80C600A105AB165。

- **标准化编码流程**
  - 多个项目中不同描述对应同一通用材料代码，体现系统对多样化表达的归一化能力。
  - 如无缝钢管在不同项目中描述各异，但均映射为P25S80A106AB3610。
  - 尺寸单位可自动转换，如“1寸”识别为DN25，确保输入多样性下的输出一致性。

当前技术实现方案

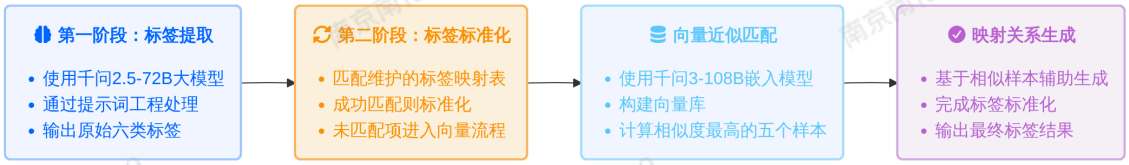

- **双阶段处理架构**
  - 第一阶段使用千问2.5-72B大模型通过提示词工程提取原始六类标签。
  - 第二阶段结合维护的标签映射表进行标准化，未匹配项进入向量近似匹配流程。
  - 利用千问3-108B嵌入模型构建向量库，计算相似度最高的五个样本辅助生成映射关系。
- **人工反馈与数据补证**
  - 建立包含数万行数据的人工核对反馈库，用于修正模型输出错误。
  - 通过原始种类与修正种类建立新映射条目，持续完善标准化体系。
  - 映射表动态更新，支持后续自动化匹配准确率提升。

现存问题与挑战

- **模型泛化与识别精度**
  - 模型对训练集外差异较大的样本识别能力弱，泛化性能不足。
  - 字符级训练方式导致粘连字段切分困难，如“400M”无空格时难以正确分割。
  - 提取过程中出现误切现象，如以SC开头的英文词被误判为SCH壁厚标识。
- **处理效率与并发瓶颈**
  - 千问72B模型推理速度慢，200条数据处理耗时超一小时。
  - 部署平台MaxCompute不支持真正并发，制约批量处理效率。
  - 当前采用将相似样本合并提交的方式优化吞吐，但引入语义混淆风险。
- **语义混淆与匹配误差**
  - 相似但语义不同的描述在批量处理中易被统一处理，导致标签错误。
  - 向量匹配阶段虽能兜底，但仍依赖样本库覆盖度，冷启动场景表现不佳。

- 多路召回机制可能加剧并发压力，影响整体响应时间。

未来技术探索方向

- **深度学习与视觉识别**
  - 计划开展CAD图纸矢量图识别研究，目标是解析设备、管道等图形及其拓扑关系。
  - 探索将图纸分解为16×16区块进行大规模训练，借鉴行业前沿做法。
  - 结合SLAM与双目视觉技术构建三维点云，提升高斯建模精度。
- **图神经网络与优化算法**
  - 考虑引入图神经网络处理材料堆场中复杂空间路径规划问题。
  - 探索最优解统筹算法与强化学习在工程调度中的应用潜力。
  - 希望获得专业指导以明确技术路线可行性与实施路径。

合作模式建议

- **长期业务顾问机制**
  - 采用长期辅导形式，围绕实际问题提供方向性指导而非阶段性交付。
  - 定期召开会议（如每周一次），结合微信群即时沟通，灵活调整节奏。
  - 根据项目进展动态协调资源，解决顺行或阻滞状态下的各类技术难题。
- **团队协作与分工对接**
  - 团队内部设有数据构建、模型研究、软件开发等多个角色，协同推进项目。
  - 合作后建立专项沟通群组，支持多人参与讨论，明确服务对象与工作量边界。
  - 根据具体任务需求提前预约专家时间，确保高效对接与问题闭环。

待办

张笑提供团队建立的反馈库给老师审阅

安排每周定期会议与老师沟通项目进展

整理自然语言处理与深度学习方向的详细信息并发送给老师

查找之前关于图神经网络和P的聊天记录供老师参考

明确合作细节并建立沟通群组以便后续交流

◆ **会前准备：**

一、目标

将非结构化的材料描述文本转换为标准化的材料编码

- **输入示例：**

异径三通(纵向剖分成对包装);SMLS;BW;SF304;无缝管件;GB/T12459(II);GB/T13401;ϕ133Xϕ89;3.5 mmX3.5mm;DN125x80

- **输出示例：**

RTP125x803.5MM304GBT12459IIGBT13401

1. **路线一：**

> (1) **思路和技术路线**

- 先使用Qwen2.5-72B模型，通过语义理解，模式识别，上下文推理最终通过提示词来辅助和限制大模型输出结构化的标签。进行六类标签提取(种类，尺寸，壁厚，磅级，材质，规范)，技术上以提示词工程为主；
- 对大模型提取的六类标签进行标准化处理（比如OD-DN转换,规范排序,工艺保留,锻制处理,异径处理,dn去重,连接符拆分,字符处理,双壁厚处理,lp/pn识别,规范年份处理；astm扫描归类；冲突修正等40余条规则）
- 标准化后的六类结构标签在数据库（标签库，反馈库）中进行向量匹配，完全匹配直接输出编码
- 对于没有匹配的标签用嵌入模型(Qwen3-Embedding-8B)计算相似度，从数据标签库中选中找出5个相似度最高的样本，使用这5个样本构建动态提示词给大语言模型，让大语言模型进行推理并输出最终编码，同时结合标准化结果、相似度、规则命中、标签完整度情况计算置信度。
  http://211.138.201.11:8082/

> (2) **训练集情况**

目前数据集主要有三个都是以json的形式维护,后期准备转为多维表维护：

- 标签库(基于历史项目编码)，一共12042条（壁厚：5935；尺寸：4051；材质：518；磅级：58；种类：1107；规范：373）

```
"材质": {
    "L245": "L245",
    "8163-20": "20",
    "47008-20": "20",
    "5310-20G": "20G",
    "15CrMoG": "15CrMoG",
    "A1O5": "A105",
    "20": "20",
    "20G GB/T5310": "20G",
    "20 Gr.III NB/T47008": "20III",
    "ASTM A333 GR.6": "A333",
    "ASTM A691-1.25Cr CL22": "A691",
    "NB/T47008-15CrMo Gr.III": "15CrMoIII",
    "NB/T47008-15CrMo": "15CrMo",
    "20 NB/T47008": "20",
    "ASTM A691 Gr.1.25Cr CL22": "A691",
    "15CrMo NB/T47008": "15CrMo",
    "15CrMo Gr.III NB/T47008": "15CrMoIII",
    "ASTMA333 GR.6": "A333",
```

- 反馈标签库(基于人工核对产生的错误编码)，一共1891条（壁厚：264；尺寸：288；材质：190；磅级：26；种类：628；规范：495）

```
"种类": {
  "45度等径斜三通;Seamless;BW": "45LT",
  "Eccentric reducer;Welded": "REW",
  "异径三通;WELDED + 100% RT;BW": "RTW",
  "45度弯头;5D;WELDED": "45EL5DW",
  "等径三通;Welded + 100% RT;BW": "TW",
  "等径三通;WELDED + 100% RT;BW": "TW",
  "Eccentric reducer;Welded + 100% RT;BW Ends": "REW",
  "盲法兰;RF;NPT": "BFN",
  "Eccentric Reducer;Welded": "REW",
  "90 Degree Elbow;Long Radius;Welded": "90ELW",
  "45度等径三通;SMLS;BW": "45LT",
  "夹套盲法兰;RF": "BFJ",
  "盲法兰; NPT": "BFN",
  "Blind Flange;NPT": "BFN",
  "Blind Flange;RF": "BF",
```

- 规范分类库一共119条（生产和制造标准）,一共121个标准(制造标准:99个；生产标准21个；施工及验收标准1个)

```
"raw_mapping": {
  "ASME B31.3": "制造标准",
  "ASME B16.9": "制造标准",
  "ASME B1.1": "制造标准",
  "ASME B18.2.2": "制造标准",
  "MSS SP-97": "制造标准",
  "MSS SP-95": "制造标准",
  "SH/T 3419": "制造标准",
```

(1) **目前还存在的问题**

- 在mac studio上能否使用mlx架构或者其他架构进行异步推理?
- 怎么看待训练大模型和微调大模型对于此情景下的运用优劣?
- 怎么解决大语言模型在一阶段提取的时候结构化稳定性不足，比如在壁厚标签没有的情况下，大模型会倾向于补全，其他标签也有此类情况，先解决方式是提示词强约束，但是对于材料描述元素比较混乱，大模型还是会出现此类情况，那么意味着提示词将会越来越多，对于后续应该是提示词转成规则补充还是把提示词转成训练集更合适？如果转成训练集，以哪种方式去生成训练集会比较好?
- 对于检索召回不足，比如嵌入模型在使用余弦定理并不足以给大模型进行推理，此类召回问题也尝试使用编辑距离，但效果都不是很好，是否有更好的方式?
- 对于知识库的补全，前期尝试使用联网搜索searxng，但是对于什么情况下使得大模型触发联网功能？怎么压缩知识和提取联网搜索结果给大模型?
- 性能问题，处理速度较慢，如何提升处理速度。
- 准确率问题，为了提高速度我们使用批量化处理，批量化处理存在上下文污染问题，每10条相似的描述进入同一个队列，使用相似的提示词+相似描述+AI模式泛化，导致的污染问题。

> (1) **现状和目标**

- 现状:准确率85%左右，单条生成速度约23秒，多并发14秒左右，准确率和处理速度都不尽人意。
- 目标:准确率95%以上，单条生成速度10秒，多并发5秒左右，可以投入正式使用。

2. **路线二：**

> (1) **技术方案**

- 采用**“NER分词 + Seq2Seq编码 + 固定顺序拼接”**的流程：

原始文本 → BERT NER(字符级) → 实体提取 → Seq2Seq编码 → 固定顺序拼接 → 材料编码

- **定义6类实体标签：**

实体类型	提取	编码结果
TYPE（种类）	异径三通(纵向剖分成对包装)	RTP
MATERIAL（材质）	SF304	304
SIZE（尺寸）	ϕ133Xϕ89 | DN125x80	125x80
THICKNESS（壁厚）	3.5 mmX3.5mm	3.5MM
PRESSURE（磅级）		
STANDARD（规范）	GB/T12459(II) | GB/T13401	GBT12459IIGBT13401

- **模型架构：**

> - NER模型：xlm-roberta-base（字符级微调，BIO标注）
> - 编码模型：mt5-small（将提取的实体转换为标准编码）

(1) **三、当前遇到的问题**

- **问题1：模式泛化能力差**

训练集中标注了 ELBOW 45-deg 为TYPE，但遇到以下变体会识别失败

例如：

- ELBOW(45-deg) — 括号形式

ELBOW(45-deg) ASTM A403 Gr.WP304 LR SMLS BW ASME B16.9 SCH40S;DN150

  - figure 8 blanks — 训练过 Figure 8，但加了 blanks ，识别的种类是“FIGURE-8”和“LANK”

FIGURE-8 BLANKS ASTM A182 GR.F316L CL150 RF ASME B16.48DN25

FIGURE-8 ASTM A182 GR.F316L CL150 RF ASME B16.48DN25

- **问题2：语义歧义（数字尺寸 vs 壁厚）**

FLANGE LAPPED TYPE 33 DIN EN 1092-1 88.9 AISI 316L;DN80

  - 88.9 是外径尺寸（SIZE）
  - 但模型将其误识别为壁厚（THICKNESS）
  - 两者都是纯数字，模型难以从上下文区分

- **问题3：顺序敏感**

训练集大部分是 "种类在前" 的格式：

异径三通;SF304;DN125x80;...

遇到顺序调换的输入：

ϕ133Xϕ89;3.5 mmX3.5mm;DN125x80;异径三通;SF304;...

模型无法正确识别出实体。

- **问题4：字符级模型会不合理地切割单词**
  - **BLANKS → 被切成 B、LAN、KS，导致边界错误**
  - **LENGTH=91.6298 → 被切成 LENGT 和 H=91.6298，H=91.6298被误识别为其他标签**

- 目前的应对方式是：**不断添加数据覆盖新模式**
  - **每遇到一种新变体，就手动添加训练样本**

- 重新训练模型

BERT应具备泛化能力，但目前泛化能力不够理想。

四、数据集

- **目前bert数据集格式**
  {"text": "Elbow, LENGTH=85.0904, DIN EN ISO 1127 - S30408;DN200", "ner_labels": ["B-TYPE", "I-TYPE", "I-TYPE", "I-TYPE", "I-TYPE", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "B-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "O", "O", "O", "B-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "O", "B-SIZE", "I-SIZE", "I-SIZE", "I-SIZE", "I-SIZE"], "type_class": "管件", "type_entity": "Elbow"}

{"text": "ELBOW, R=39, A=90°, L1=22, L2=36, DIN EN ISO 1127 - AISI 316L;DN150", "ner_labels": ["B-TYPE", "I-TYPE", "I-TYPE", "I-TYPE", "I-TYPE", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "B-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "I-STANDARD", "O", "O", "O", "B-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "I-MATERIAL", "O", "B-SIZE", "I-SIZE", "I-SIZE", "I-SIZE", "I-SIZE"], "type_class": "管件", "type_entity": "ELBOW"}

- **seq2seq模型数据集格式**

{"input": "不锈钢管件同径三通", "output": "T"}

{"input": "90-ELBOW", "output": "90EL"}

{"input": "90DEG弯头 ELBOW 90DEG", "output": "90EL"}

{"input": "90DEG弯头ELBOW90DEG", "output": "90EL"}

{"input": "不锈钢锻制管帽", "output": "CAP"}

{"input": "异径45°斜TEE", "output": "45RLT"}