基于NER模型训练的石化管道材料唯一编码探索与应用

夏 斐 刘 念 徐正玲
南京南化建设有限公司 江苏南京 210044

摘 要 提出了一种基于Transformers框架命名实体识别(NER)模型的材料唯一编码方法,用BERT模型进行NER任务的训练与验证,并结合三维模型,通过流水号与唯一编码的绑定,进一步实现编码数据的自动回写与施工信息管理。

关键词 材料编码 Transformers 模型训练 命名实体识别
中图分类号 TP391.1;TQ082 **文献标志码** B **文章编号** 1672-9323(2025)01-0022-06

目前,石油化工行业的管道材料编码方式主要依赖于设计院的内部标准,这些编码方式在应用中存在无材料编码、编码不唯一、尺寸编码不唯一、编码系统复杂多样等问题,无法实现统一管理,给实施石油化工项目带来了材料管理复杂、采购成本增加、施工排程难度增加、项目进度受阻等多方面的挑战[1]。

为了有效解决上述问题,提出了一种基于NER模型的材料编码标准化方法,通过对材料描述进行智能化的分解和编码,实现不同设计院之间编码规则的统一。

1 材料编码标签体系设计

1.1 标签体系定义

为了实现对管道材料的描述进行有效的分解和编码,首先对材料的核心属性进行了分析,并定义了六个关键数据标签:类型、尺寸、壁厚、磅级、材质、标准。这些标签覆盖了管道材料的主要特征,能够支持对材料进行准确的识别与分类[2]。在对部分分区或单元进行专料专用时,可在以上六个标签生成的材料编码基础上增加分区后缀,同步在材料管理全流程中运用。

1.2 标签库构建

标签库的构建是实现材料编码标准化的基础。采用了正则表达式(Regex)技术[3],对项目中的材料描述文本进行初步解析。通过对文本中的关键词和数字进行模式匹配,提取出材料的类型、尺寸、材质等信息,并将其映射到相应的标签。通过不断扩充标签库,可以覆盖项目中大部分常见的材料描述。然而,仅靠正则表达式无法完全处理所有复杂的材料描述。例如,某些材料描述中可能存在多个属性交叉的情况,或者描述不够规范,且正则表达式过分依赖于空格等间隔符号,无法准确识别“碳钢法兰”是属于“碳钢”和“法兰”两种不同属性。因此,有必要进一步引入自然语言处理技术,对材料描述进行更为精准的解析和编码。

2 管道材料NER模型设计与实现

通过自然语言处理技术对管道材料描述进行自动化分解和编码过程包括几个主要步骤。

2.1 数据预处理与分词标签

在构建NER模型之前,首先对管道材料描述文本进

行数据预处理，具体流程如下：

（1）数据清洗：对原始材料描述数据进行清洗，去除无关字符、冗余符号和非必要信息，确保数据的一致性和完整性。数据清洗主要采用正则表达式（Regex）对文本进行模式匹配，提取关键属性。

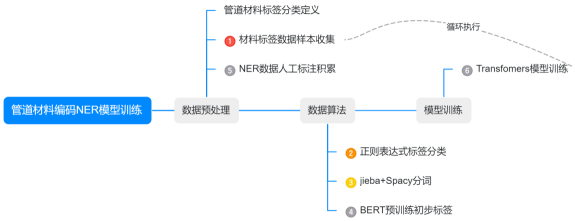

图1 管道材料NER模型训练流程

（2）中英文分词：由于材料描述通常包含中英文混合的字段信息（如标准、材质等），采用Spacy（处理英文部分）和Jieba（处理中文部分）结合的分词方式，对文本进行逐词分解，并通过自定义词典增强分词的准确性，确保每个材料描述中的实体信息能够被准确识别。

图2 管道材料进行BER分词

（3）标签映射：基于分析结果，将文本中的每个材料属性进行实体标注，采用BIO（Beginning，Inside，Outside）标记体系，对每个实体的位置进行标记。比如，“PIPE，ASTM A106 GRADE B，SCH20 DN600”会被标记为B-TYPE（PIPE）、B-MATERIAL（A106）、B-STANDARD（ASTM）等。人工审查和标注的实体数据为后续的模型训练提供了高质量的标注数据集。

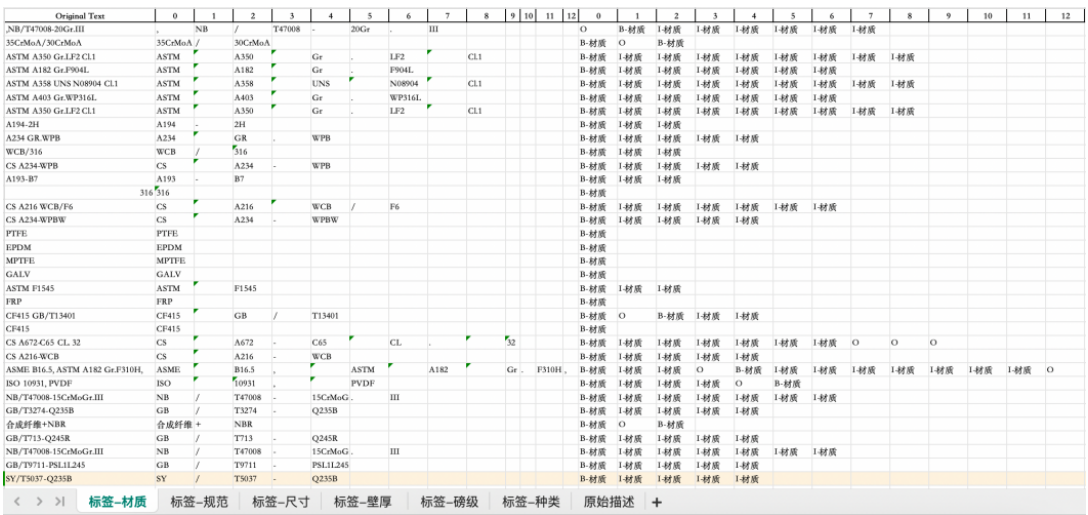

图3 分词后材料代码进行标签标记

（4）数据增强：为了提高模型的泛化能力，特别是应对不同设计单位材料描述的差异，采用了数据增强技术，生成更多的材料描述样本。方法包括同义词替换、实体顺序变换等。通过数据增强技术，扩充了训练数据的覆盖面，增强了模型的稳健性。

分词后的文本数据经过人工审查和标注，将每个实体的开始、内部及结束位置进行标记，并分配相应的tag_id。这部分处理为后续的NER模型训练提供了结构

化的数据输入。

2.2 NER模型训练

基于BERT 预训练模型构建了命名实体识别(NER)系统,用于识别复杂的材料描述。BERT 模型强大的语言理解和上下文捕捉能力,使其在处理长尾数据和不规则材料描述时具备极高的准确率。模型训练依托Pytorch和transformers[4]框架,主要流程如下。

(1)数据输入与序列化:在NER任务中,输入模型的文本必须经过适当的预处理。首先,标注好的材料描述文本通过分词器(Tokenizer)进行切分,生成对应的token 序列。由于不同的材料描述存在长度差异。例如“90度长半径弯头,GB/T8163-20,BE,SH/T3408,SMLS,DN200,S-STD”含有23个token,而“带颈对焊法兰,ASTM,A182 Grade F304(UNSS30400),RF,CL150,ASMEB16.5,DN80,S-10S”只有19个token,必须对序列进行统一处理。为此,模型在输入之前需要对序列进行padding操作,将较短的序列填充至同一长度。填充部分使用特殊符号[PAD],以确保批处理操作时能够在相同维度上计算,为了确保这些填充符号不会干扰模型的训练和推理,使用了注意力掩码(attention mask)。该掩码机制会将实际的token标记为1,填充部分标记为0。

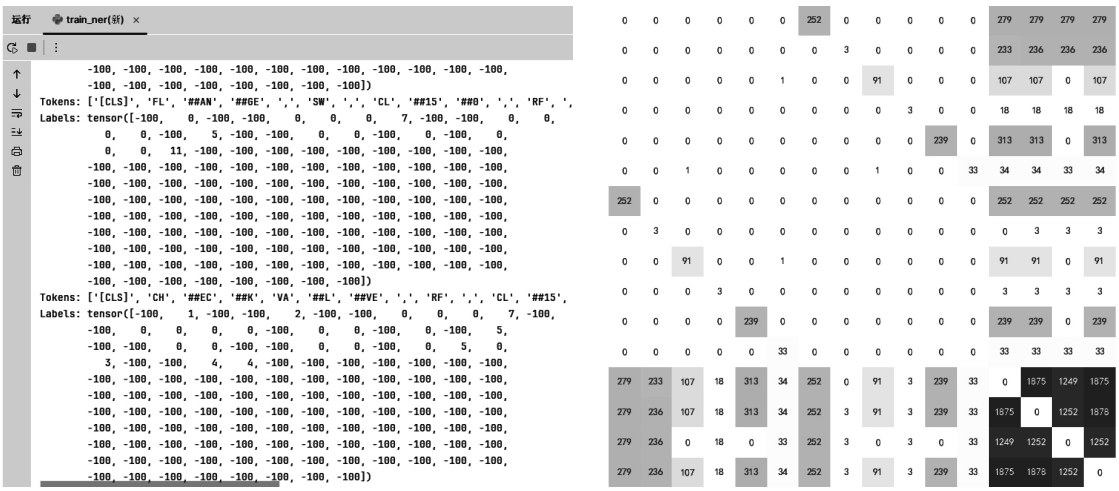
运行
train_ner(新)
-100, -100, -100, -100, -100, -100, -100, -100, -100, -100, -100, -100,
-100, -100, -100, -100, -100, -100, -100])
Tokens: ['[CLS]', 'FL', '##AN', '##GE', ',', 'SW', ',', 'CL', '##15', '##0', ',', 'RF', ',
Labels: tensor([-100, 0, -100, -100, 0, 0, 0, 7, -100, -100, 0, 0,
0, 0, -100, 5, -100, -100, 0, 0, -100, 0, -100, 0,
0, 0, 11, -100, -100, -100, -100, -100, -100, -100, -100, -100,
-100, -100, -100

同(如“DN600”和“600mm”),数据增强使模型能够处理更多样化的输入,提高了其识别的鲁棒性。

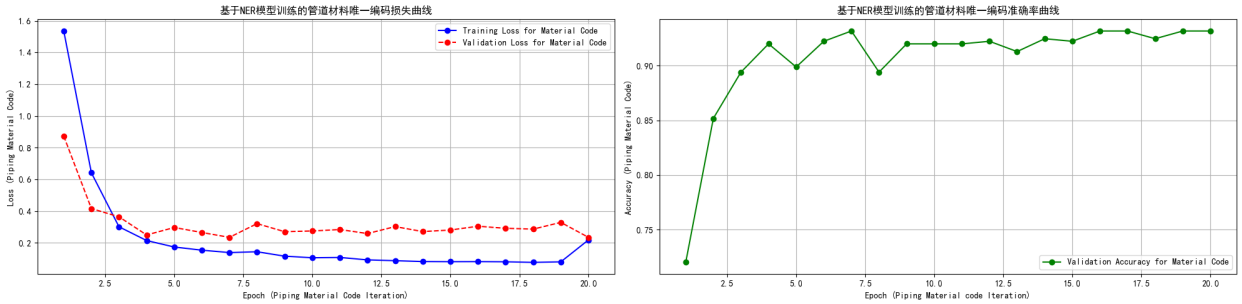

图5 Transformers 训练损失下降及准确率上升曲线

2.3 模型评估与代码还原

(1)模型评估:在模型训练完成后,通过在包含1万条未见过的材料描述文本的测试集上进行评估,模型在precision(精确率)、recall(召回率)和 F1-score(F1分数)方面都达到了较高的水准。测试结果表明,基于BERT的NER模型不仅能够高效识别标准和材质等材料描述的属性信息,还具备较强的泛化能力,能够处理结构复杂的描述。经过动态学习率和数据增强策略的优化,模型在不同类型的材料描述中的表现更为稳定。

```
example 1: PIPE , PE , SMLS , ASTM A790 GRADE S32205 , ASME B36.19M , SCH40S DN40
Tokens                  True Labels        Predicted Labels   result
PIPE                    B-NAME             B-NAME             ✓
,                       O                  O                  ✓
PE                      O                  B-NAME             ✗
,                       O                  O                  ✓
SMLS                    O                  O                  ✓
,                       O                  O                  ✓
ASTM A790 GRADE S32205  B-MATERIAL         B-MATERIAL         ✓
,                       O                  O                  ✓
ASME B36.19M            B-STANDARD         B-STANDARD         ✓
,                       O                  O                  ✓
SCH40S DN40             B-THICKNESS B-DIM  B-THICKNESS B-DIM  ✓
--------------------------------------------------------------
```

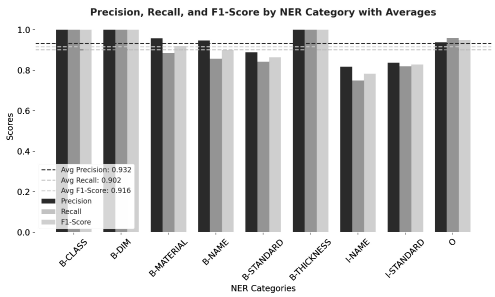

图6 不同标签模型训练评估对比

(2)模型预测:模型接收输入的token序列后,利用多头注意力机制处理上下文信息,对每个token的嵌入表示进行推理。BERT 模型输出每个token对应的标签概率分布,即每个token可能属于哪个实体类别(例如 B-NAME、B-MATERIAL、B-STANDARD等)。为了提取出最可能的标签,模型会通过参数最大值argmax操作,从预测的概率分布中选取概率最大的标签作为每个token的最终预测结果。

例如,给定材料描述文本“PIPE,PE,SMLS,ASTM A106 GRADE B,ASME B36.10M,SCH20 DN600”,模型能够准确预测以下标签:

○ B-NAME(PIPE):实体名称

○ B-MATERIAL(A106):材料标准

○ B-STANDARD(ASME):标准规范

○ I-STANDARD(B36.10M):标准的扩展部分

○ B-THICKNESS(SCH20):壁厚

○ B-DIM(DN600):尺寸

这些识别出的标签及其对应的实体为下游任务,如材料分类、属性提取等,提供了基础信息。

(3)还原材料描述代码:在模型完成实体识别后,下一步是将这些实体标签转换回原始的材料代码或结构化描述。该过程包括将模型输出的token和对应的标签重新组合为统一的材料描述。具体步骤如下:

①实体拼接:将分配有相同标签的连续token进行拼接。例如,模型输出将“ASTM”标记为B-STANDARD,而“A106”标记为I-STANDARD,这两个token会拼接为完整的材料标准“ASTM A106”。

②标签组装:将不同类别的实体标签组合为统一的材料描述代码。例如,“B-NAME(PIPE)”“B-MATERIAL(A106)”“B-STANDARD(ASME B36.10M)”“B-THICKNESS(SCH20)”和“B-DIM(DN600)”会被还原为一个完整的材料描述:“PIPE,

ASTM A106 GRADE B，ASME B36.10M，SCH20 DN600”[5]。

③特殊符号与格式处理：在组装过程中，模型预测的实体标签会保持其原有的格式，例如逗号、空格等特殊符号。这些符号会根据原始描述的格式规则进行保留或适当调整，以确保还原后的材料代码与原始格式一致。

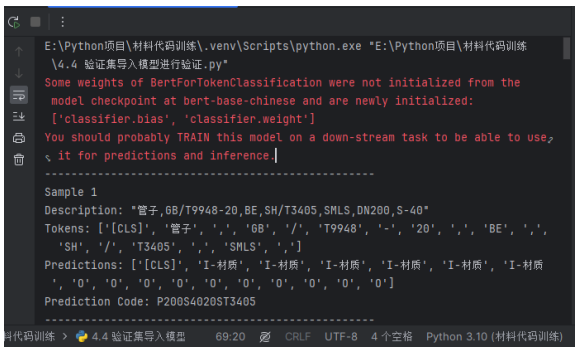

图7 实体拼接及还原预测

3 材料唯一流水号及可视化

管道材料编码规则统一化后，实现了项目材料的数据一致性和汇总计算，然而在实际的排产和追溯过程中，同规格材料大概率会分布在不同管段和管线中，因此需要进一步将焊缝和材料编码进行绑定，生成对应的唯一追溯码，实现一物一码的精细化管理要求。因此进一步研究通过自动编号和流水号技术，实现了材料唯一性识别，并通过管道连接、流向、元件特征等因素优化了编号逻辑，确保了项目中材料的统一管理与高效追溯[6]。

3.1 流水号自动编号与唯一编码生成

结合NER模型生成的标签数据，系统进一步优化了管道的自动编号流程。管道焊口和元件的自动编号依赖于管道流向、主管与支管的关系。这种基于拓扑关系的自动编号技术通过解析管道的连接和流向，自动生成流水号，实现了从材料描述到管道编号的统一性，确保了项目管理中的数据一致性和追溯性。流水号不仅适用于焊口表的展示，还可写入模型的属性中，形成最终的材料唯一编码。

例如，针对多个相同的三通元件，系统会依次生成“材料代码-01”“材料代码-02”等编号，确保每个元件的唯一性。在直管段分段的情况下，每个分段都会获得不同的材料编码和流水号。通过这种方式，系统确保了元件和焊口在整条管线中的唯一标识。

序号	管线号	元件编号	材料代码	类型	材料名称	材料描述
1	CWR860201-80-2B1	90EL80S40A234AB169-55	90EL80S40A234AB169	管件	90 DEGREE ELBOW	90-ELBOW,BW,SMLS,LR,A
2	CWR860201-80-2B1	BF20C150A105AB165-25	BF20C150A105AB165	法兰	BLIND FLANGE	BLD FLANGE,CL150,RF,AS
3	CWR860201-80-2B1	F80S40C150A105AB165-28	F80S40C150A105AB165	法兰	FLANGE	FLANGE,WN,CL150,RF,AS
4	CWR860201-80-2B1	FS20S80C150A105AB165-59	FS20S80C150A105AB165	法兰	FLANGE	FLANGE,SW,CL150,RF,AS
5	CWR860201-80-2B1	FS40S80C150A105AB165-31	FS40S80C150A105AB165	法兰	FLANGE	FLANGE,SW,CL150,RF,AS
6	RV850101-200-2B4	F200S20C150A105AB165-11	F200S20C150A105AB165	法兰	FLANGE	FLANGE,WN,CL150,RF,AS
7	SL860201-80-5K3	90EL20S160316LAB169-20	90EL20S160316LAB169	管件	90 DEGREE ELBOW	90-ELBOW,BW,SMLS,LR,A
8	SL860201-80-5K3	BF20C600316LAB165-7	BF20C600316LAB165	法兰	BLIND FLANGE	BLD FLANGE,CL600,RJ,AS
9	SL860201-80-5K3	F20S160C600316LAB165-28	F20S160C600316LAB165	法兰	FLANGE	FLANGE,WN,CL600,RJ,AS
10	SL860201-80-5K3	F80S40SC150316LAB165-22	F80S40SC150316LAB165	法兰	FLANGE	FLANGE,WN,CL150,RF,AS

图8 生成唯一编码材料基础库

通过LUA脚本逻辑实现编写，确定了管件编码的优先顺序，包括主管支管、密封面类型、流向等属性。这些参数通过预定义的优先规则在管道元件和材料中进行排序，使得编码生成逻辑能够处理复杂材料描述。为了避免材料编码重复或遗漏，系统通过流水号确保在同一张图纸中的材料具有唯一编号。此外，编码还考虑到设计图纸的分图点划分和材料流向，确保编码的一致性和连续性。

3.2 数据回写与模型反馈

在生成材料唯一编码后，采用了流水号与材料编码绑定的方式，通过解析IDF/PCF文件，识别管道元件的端面类型和连接方式，形成材料编码的基础数据。

系统通过反写入技术，将这些编码数据回写至三维模型中，实现了材料管理的可视化与数据化。在模型中，每个管道元件的材料编码、流水号、消耗量等信息均能够自动显示，极大地提高了项目的管理效率和透明度[7]。此外，该系统能够实时跟踪材料的使用情况，并根据项目变更自动更新三维模型中的相关数据，为施工团队提供更加直观的现场指导。

4 项目应用效果与未来展望

以某境外生物燃油项目为例，本技术成功实现了9个不同设计院的材料描述统一编码，有效解决了变径、支管台、直管重复映射等材料编码过程中遇到的实际问题。项目中，共对9345张ISO图纸中的5589种材料代码进行批量替换，并依据管件分类、端面类型和分支形式建立了拓扑关系，从而实现所有管道元件“一物一码”属性的自定义，形成了公司统一的二次设计标准。此举为快速成本分析、材料与焊工排程等管道焊接的数字化管理，提供了便捷的底层数据库映射与标签支持。

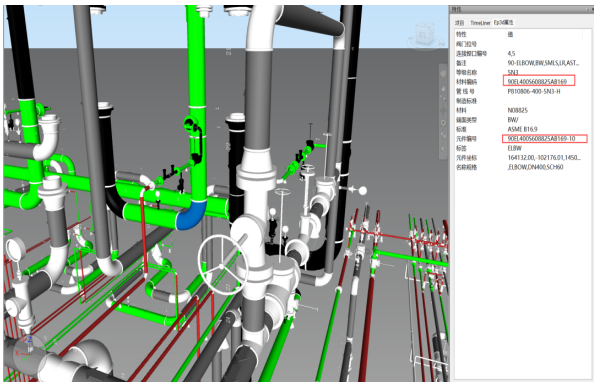

图9 唯一编码材料代码反写入模型

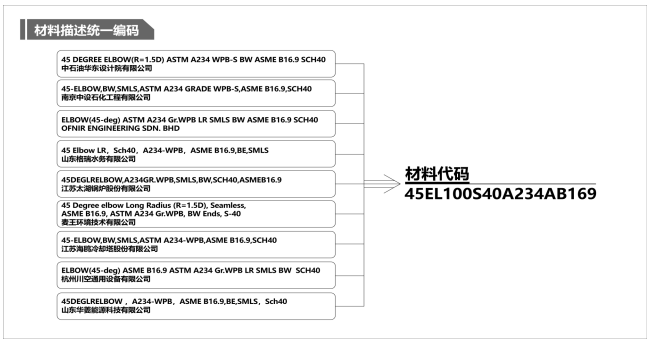

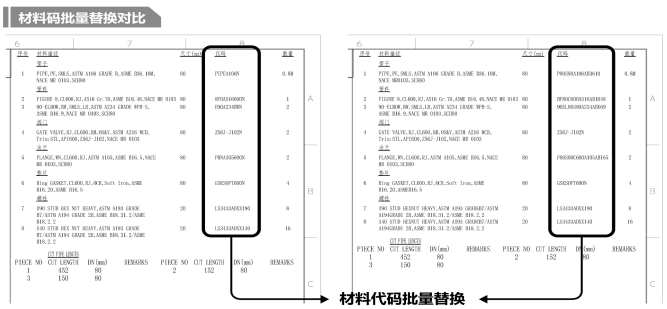

图10 不同设计院材料代码统一化及图纸材料代码替换

项目实施过程中，管道预制量从初步估算的13.8万DIN增加至18.3万DIN。通过“一物一码”自定义技术，进一步优化了高峰期45组焊工的排程，项目管工配置数量减少了11.2%，并超出预测效率6.3DIN/d，日均效率提高了14%。预制全过程领先基准工时计划，最高峰时进度领先21.6%，焊接合格率维持在99.3%。最终，实现了安全、质量和进度全面领先的优秀管理目标。

通过加强数据质量和培养模型团队，项目数据累积实现模型迭代优化，推动管道数字化智能排程与成本分析管理水平提高，助力石化建设行业转型升级。

参考文献

[1] 梁延辽．材料编码在EPC项目设计和管理中的应用[J]．化工设计通讯，2021，(9)：136−137．

[2] 庞东，张怡，王喜全，等．管道材料编码标准化开发及应用[J]．石油工程建设，2018，44(增刊1)：163−167．

[3] 高丙坤，成战刚，李倩．基于正则表达式的信息滤除算法[J]．现代计算机，2008，14(2)：54−55，64．

[4] 颜婷婷，戎慧敏．基于BERT−Transformer的跨语言文本摘要技术研究[J]．平顶山学院学报，2023，(5)：61−64．

[5] 宋建炜，邓逸川，苏成．基于预训练语言模型的建筑施工安全事故文本的命名实体识别研究[J]．图学学报，2021，(2)：307−315．

[6] 张小钢，宋峥嵘，李金来．材料编码映射辅助系统设计应用分析[J]．中国勘察设计，2014，(7)：88−90．

[7] 付仁超，刘雪，李科．三维工厂设计系统中材料代码的替换[J]．山东化工，2014，(6)：150−152．

(收稿日期：2024−10−17)